최신 트렌드

GTC 2026 젠슨 황 기조연설 + 정리

최지훈

GTC 2026 Keynote

- GTC(GPU Technology Conference)
  - 단순 GPU 파는 용산 아저씨가 아니다

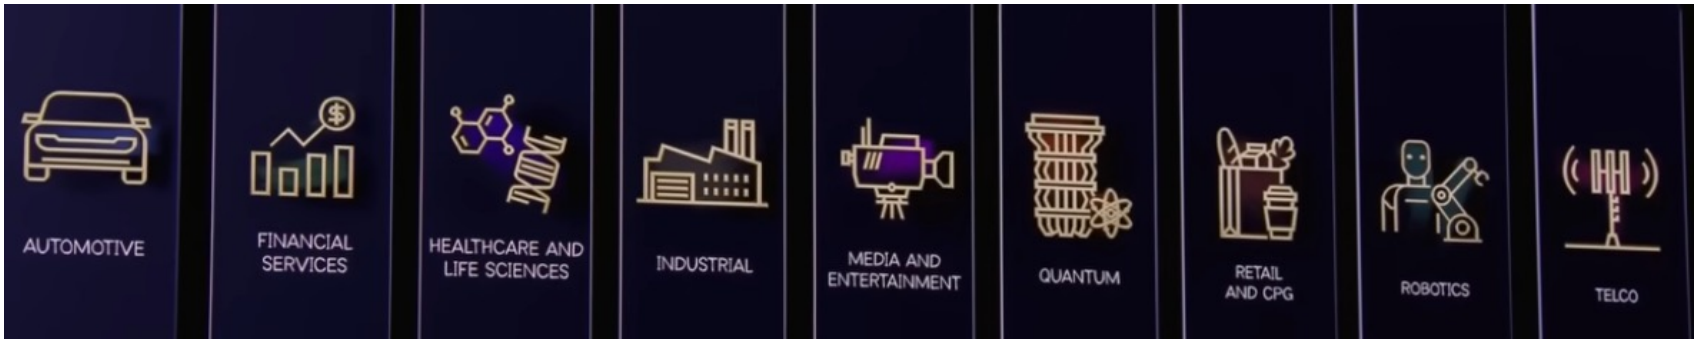

  - 이런 다양한 산업에 우리는 진행하고 있고 최고가 될거임.
  - 올해의 핵심 축
    - AI 팩토리, 에이전트 AI, 추론(inference king), 피지컬 AI

GTC 2026 keytnote : https://www.youtube.com/watch?v=jIviHI7fqyc

- 추론 과 운영에 초점을 맞춤
  - 토큰의 사용량이 많고 메모리, gpu 등등 부족함
  - 똑똑한 ai를 얼마나 싸고 빠르고 안정적이게 굴릴 수 잇는가?
  - CUDA -X (가속 라이브러리 생태계가 됨.)
  - 시스템 : 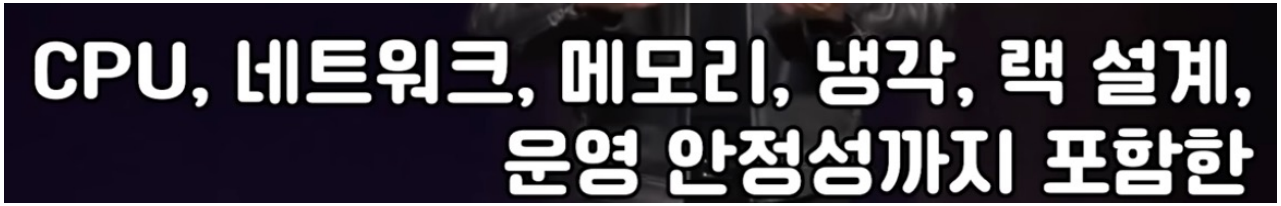

    - 우리 랙 사주지 않을래? 베라 루빈 좋아.. 울트라까지 나왓어.
  - 인식하는 AI > 생성하는 AI > 추론하는 Ai > 작업 수행 AI
    - 작업 수행에 있어서 보안, 네트워크, 운영에 중요성이 생겨짐.
    - 작업 수행 AI -> openclaw 좋더랑 그래서 우리꺼 만들거야 그래서 시스템 연동 인프라를 생성할거임. ㅋㅋ

- 산업군별 AI 모델 개열을 만들어버려야지
  - Cpu도 중요해짐
  - 에이전트의 툴과 스케줄링 네트워크도 해야함
  - 베라 cpu임 에이전트 ai 를 위해서 만들거임

  - 칩들 사이를 연결하는 nv link도 초점임
    - 랙 내부를 하나의 gpu 처럼 묶는 nv link라는게 있음

    - 데이터 통신도 빠르게 해야하니 광통신으로 해야함

    - 네트워크, 전력,냉각으로 이동하고 있음

  - Groq3 LPX -> LPU 추론 가속기를씀
    - 이로써 말하고 싶은건 cpu gpu lpu 네트워크 등 묶임이 중요함
  - 데이터센터안의 발열등 을 저전력 메모리로 풀겠다는 신호가 있더라.

- GTC 로 HBM4 다음세대 준비하면서
  - 엔비디아 제조로 삼성이 선택됨.
  - **H**igh **B**andwidth **M**emory (HBM)
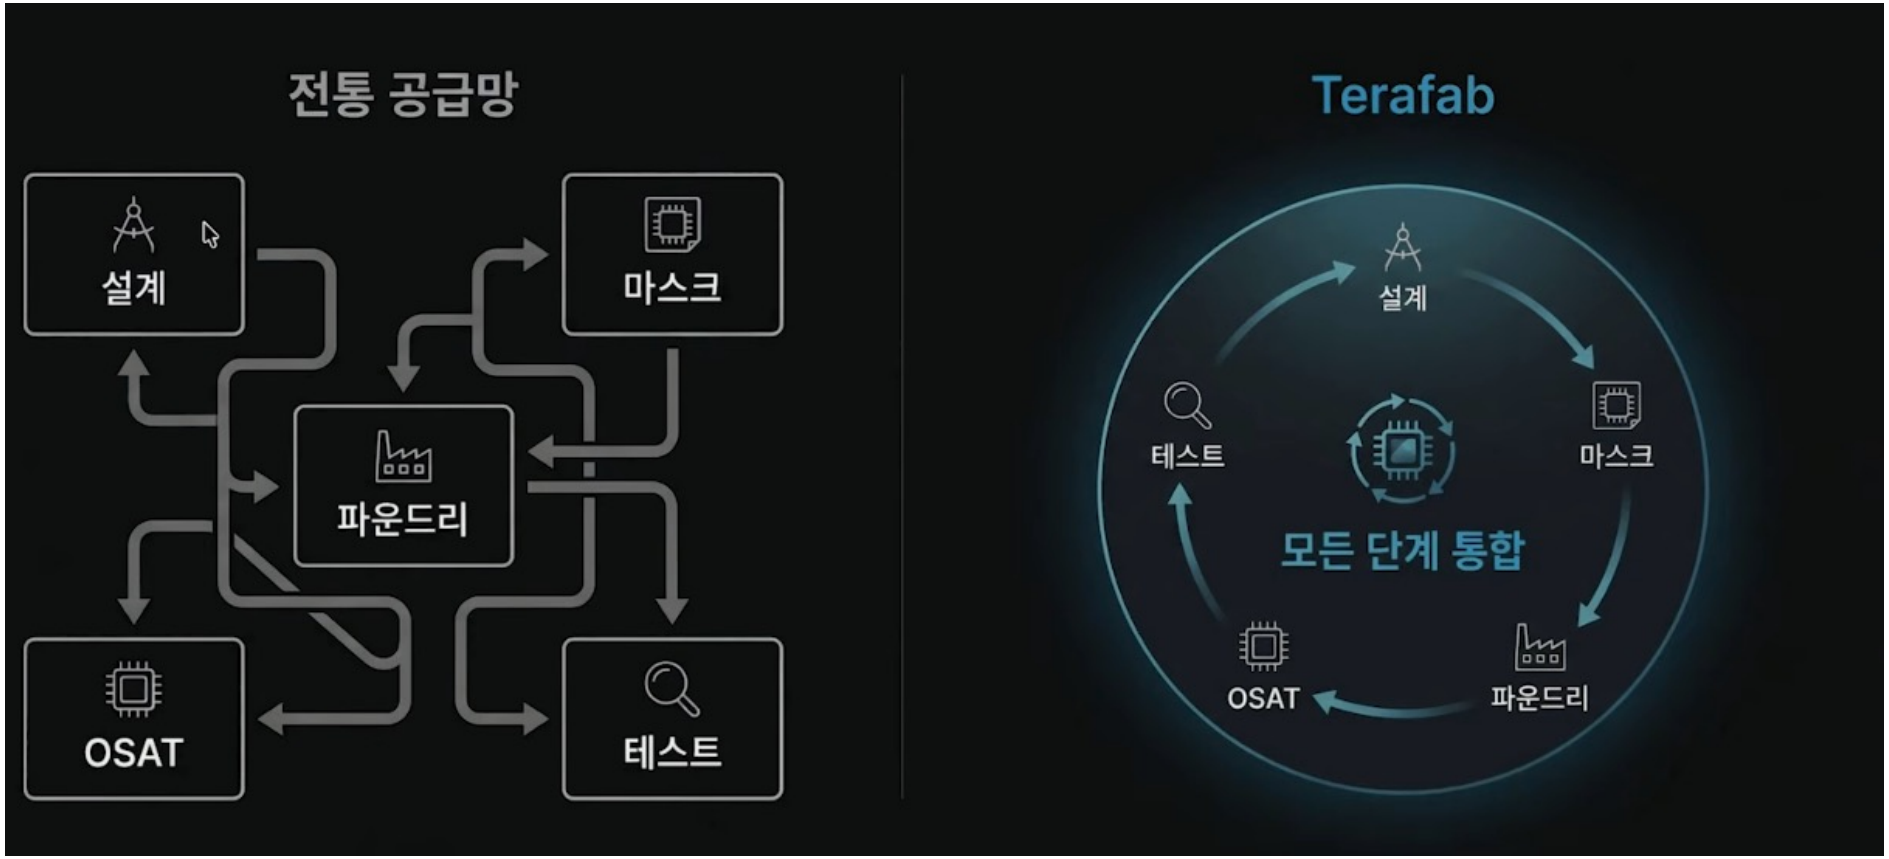
Terafab (일론머스크)